類神經網路訓練不起來怎麼辦 (一): 局部最小值 (local minima) 與鞍點 (saddle point)


Create at 2022/06/08

- 類神經網路訓練不起來怎麼辦 (一): 局部最小值 (local minima) 與鞍點 (saddle point)
 - o Optimization 時怎麼把 gradient descent 做得更好
 - <u>為甚麼 optimization 會失敗呢?</u>
 - Saddle Point 跟 Local Minima 誰比較常見?
- 上課資源:
 - 1. <u>類神經網路訓練不起來怎麼辦 (一): 局部最小值 (local minima) 與鞍點 (saddle point)</u> (https://www.youtube.com/watch?v=QW6uINn7uGk)

Optimization 時怎麼把 gradient descent 做得更好

為甚麼 optimization 會失敗呢?

Optimization Fails because



- 隨著參數不斷 update, training loss 不會再下降
- 但是對於這個 loss 仍然不滿意
- 有時候會發現 model train 不起來,不管怎麼 update 參數 loss 都掉不下去
 - o 猜想:走到一個點,這個點對 loss 的微分為 0,當對 loss 的微分為 0 時, gradient descent 就沒辦法再 update 參數,此時 training 就停下來了,參數不再 update,loss 就不會再下降了
- 不是只有 local minima 的 gradient 為 0
- saddle point 的 gradient 是 0,但不是 local minima 也不是 local maxima
- gradient 為 0 的點,統稱為 critical point
- 可以說 loss 沒辦法再下降,可能是卡在 critical point

Warning of Math

可以跳過沒關係

Tayler Series Approximation

 $L(\boldsymbol{\theta})$ around $\boldsymbol{\theta} = \boldsymbol{\theta}'$ can be approximated below


$$L(\boldsymbol{\theta}) \approx L(\boldsymbol{\theta}') + \left[(\boldsymbol{\theta} - \boldsymbol{\theta}')^T \boldsymbol{g} \right] + \left[\frac{1}{2} (\boldsymbol{\theta} - \boldsymbol{\theta}')^T \boldsymbol{H} (\boldsymbol{\theta} - \boldsymbol{\theta}') \right]$$

Gradient g is a vector

$$\mathbf{g} = \nabla L(\mathbf{\theta}')$$
 $\mathbf{g}_i = \frac{\partial L(\mathbf{\theta}')}{\partial \mathbf{\theta}_i}$


Hessian H is a matrix

$$\mathbf{H}_{ij} = \frac{\partial^2}{\partial \boldsymbol{\theta}_i \partial \boldsymbol{\theta}_j} L(\boldsymbol{\theta}')$$




Hessian

 $L(\boldsymbol{\theta})$ around $\boldsymbol{\theta} = \boldsymbol{\theta}'$ can be approximated below



telling the properties of critical points



2022/7/15 下午5:49

Hessian
$$L(\boldsymbol{\theta}) \approx L(\boldsymbol{\theta}') + \frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\theta}')^T \boldsymbol{H}(\boldsymbol{\theta} - \boldsymbol{\theta}')$$

For all v

$$v^T H v > 0$$
 Around θ' : $L(\theta) > L(\theta')$ Local minima

= H is positive definite = All eigen values are positive.

For all \boldsymbol{v}

$$v^T H v < 0$$
 Around θ' : $L(\theta) < L(\theta')$ Local maxima


= H is negative definite = All eigen values are negative.

Sometimes $v^T H v > 0$, sometimes $v^T H v < 0$ **Saddle point**


Some eigen values are positive, and some are negative.



$$y = w_1 w_2 x$$



Error Surface



$$x \xrightarrow{w_{1}} \longrightarrow w_{2} \longrightarrow y \iff \hat{y} = 1$$

$$L = (\hat{y} - w_{1}w_{2}x)^{2} = (1 - w_{1}w_{2})^{2}$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 2(1 - w_{1}w_{2})(-w_{1})$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 2(1 - w_{1}w_{2})(-w_{1})$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

$$= 0$$

Don't afraid of saddle point?

At critical point:
$$L(\boldsymbol{\theta}) \approx L(\boldsymbol{\theta}') + \frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\theta}')^T \boldsymbol{H}(\boldsymbol{\theta} - \boldsymbol{\theta}')$$

Sometimes $v^T H v > 0$, sometimes $v^T H v < 0$ \Longrightarrow Saddle point

H may tell us parameter update direction!

$$u$$
 is an eigen vector of H
 λ is the eigen value of u
 $\lambda < 0$

$$u^T H u = u^T (\lambda u) = \lambda ||u||^2$$
 < 0
 < 0

$$L(\boldsymbol{\theta}) \approx L(\boldsymbol{\theta}') + \frac{1}{2} (\boldsymbol{\theta} - \boldsymbol{\theta}')^T \boldsymbol{H} (\boldsymbol{\theta} - \boldsymbol{\theta}') \implies L(\boldsymbol{\theta}) < L(\boldsymbol{\theta}')$$
$$\boldsymbol{\theta} - \boldsymbol{\theta}' = \boldsymbol{u} \qquad \boldsymbol{\theta} = \boldsymbol{\theta}' + \boldsymbol{u} \qquad \text{Decrease } L$$

$$\lambda_2 = -2$$
 Has eigenvector $\boldsymbol{u} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

Update the parameter along the direction of $oldsymbol{u}$


You can escape the saddle point and decrease the loss.

(this method is seldom used in practice)

End of Warning


Saddle Point 跟 Local Minima 誰比較常見?

Saddle Point v.s. Local Minima




When you have lots of parameters, perhaps local minima is rare?

- 維度越高,可能可以走的路越多
- 所以在訓練 network 時,參數往往會很多,所以 error surface 其實是在一個非常高的維度中
- 參數有多少代表 error surface 的維度有多少



- 每一個點都代表訓練 network 訓練完之後,把它的 Hessian 拿出來進行計算,訓練到 gradient 很小,卡在 critical point,把那組參數拿出來分析,看它比較像是 saddle point 還是比較像 local minima
- 縱軸代表 training 時的 loss · loss 沒辦法再下降時
- 橫軸是 minimum ratio
- 如果所有的 eigen value 都是正的,代表 critical point 是 local minima
- 如果有正有負代表是 saddle point
- local minima 不常見

Small Gradient ...



The value of a network parameter w

Gradient 非常小的時候,有甚麼可能的解決辦法

<u>課程網頁 (https://speech.ee.ntu.edu.tw/~hylee/ml/2022-spring.php)</u>

tags: 2022 李宏毅_機器學習